ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
**KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG**

**CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM**
**Độc Lập - Tự Do - Hạnh Phúc**

# ĐỀ CƯƠNG CHI TIẾT KHÓA LUẬN TỐT NGHIỆP
# HỌC KỲ 2 NĂM HỌC 2025 – 2026

**Tên đề tài tiếng việt:** Hệ thống triển khai linh hoạt mô hình học sâu xuống thiết bị biên trong ngữ cảnh trạm giám sát y tế thông minh

**Tên đề tài tiếng anh:** A Flexible Deployment System for Deep Learning Models on Edge Devices in the Context of a Smart Healthcare Monitoring Station

**Cán bộ hướng dẫn (**Học vị, họ và tên, nơi công tác cán bộ hướng dẫn và cán bộ hướng dẫn phụ nếu có)**:** ThS. Lê Minh Khánh Hội

**Thời gian thực hiện:** Từ ngày 26/01/2026 đến ngày 30/05/2026

**Sinh viên thực hiện:**
- Sinh viên 1: Trần Thu Ngân – 22520937
- Sinh viên 2: Hồ Thị Huỳnh My – 22520897

**Nội dung đề tài:**

**1. Vấn đề và tính cấp thiết**: Việc triển khai các mô hình học sâu xuống thiết bị biên (Edge) hiện là xu hướng tất yếu trong lĩnh vực y tế để đảm bảo tính riêng tư của dữ liệu, giảm độ trễ xử lý và duy trì vận hành khi mạng không ổn định. Tuy nhiên, thực tế các thiết bị biên thường có cấu hình phần cứng dị thể (khác biệt về CPU, GPU, bộ nhớ, giới hạn nhiệt) và điều kiện vận hành biến động theo thời gian,. Trong ngữ cảnh giám sát y tế 24/7 tại các trạm y tế vùng xa hoặc nhà ở của người cao tuổi – nơi nguồn điện không ổn định hoặc dùng năng lượng từ pin thì các giải pháp triển khai thường mang tính tĩnh dễ dẫn đến nguy cơ gây quá tải, tiêu thụ năng lượng cao, suy giảm tuổi thọ thiết bị hoặc gián đoạn dịch vụ khi triển khai mô hình không phù hợp. Do đó, đề tài tập trung giải quyết bài toán xây dựng một hệ thống triển khai linh hoạt, có khả năng dự báo rủi ro về năng lượng và điều phối mô hình theo ràng buộc tài nguyên thực tế để đảm bảo tính liên tục của việc giám sát y tế.

**2. Mục tiêu của đề tài:** Mục tiêu tổng quát của đề tài là thiết kế và hiện thực hệ thống triển khai linh hoạt mô hình học sâu xuống thiết bị biên, cho phép cập nhật mô hình từ xa (OTA), quản lý phiên bản, theo dõi telemetry thời gian thực và ra quyết định triển khai theo ràng buộc năng lượng và hiệu năng suy luận. Hệ thống hướng tới đảm bảo rằng mô hình được chọn và cấu hình suy luận tương thích với trạng thái thiết bị tại thời điểm triển khai, hỗ trợ cơ chế canary và rollback nhằm giảm rủi ro khi cập nhật trong môi trường vận hành thực. Đồng thời đảm bảo cân bằng giữa năng lượng và độ trễ để kéo dài thời gian vận hành tại các khu vực khó tiếp cận hoặc hạn chế điện lưới.

**3. Phương pháp thực hiện:** Đề tài sử dụng phương pháp thiết kế hệ thống theo kiến trúc server-agent. Hệ thống được triển khai dưới dạng container để hỗ trợ quản lý fleet và cập nhật OTA thông qua các nền tảng như Docker/balena. Quy trình ra quyết định triển khai dựa trên sự kết hợp giữa dữ liệu telemetry thời gian thực và mô hình dự báo năng lượng được huấn luyện từ các kịch bản benchmark thực tế.

**4. Các nội dung chính và giới hạn của đề tài:**

**Nội dung 1:** Xây dựng bộ dữ liệu và mô hình dự báo năng lượng tiêu thụ
- Phương pháp: Tiến hành thực nghiệm đo đạc năng lượng tiêu thụ của các mô hình

Deep Learning (CNN,MobileNet và các mô hình tương tự) khi suy luận trên thiết bị biên theo nhiều cấu hình khác nhau (định dạng mô hình, độ phân giải đầu vào, batch, tần suất suy luận). Ghi nhận các chỉ số chính như năng lượng/inference, băng thông bộ nhớ, độ trễ và tài nguyên hệ thống sau đó làm sạch và chuẩn hóa dữ liệu. Áp dụng mô hình thuật toán hồi quy (ví dụ Gradient Boosting) để dự báo mức tiêu thụ năng lượng trước triển khai và tích hợp kết quả dự báo vào cơ chế ra quyết định trên Server.

- Kết quả dự kiến: Xây dựng được tập dữ liệu đo năng lượng tiêu thụ trên thiết bị biên (~500 mẫu) và mô hình dự báo năng lượng tiêu thụ đạt độ chính xác cần thiết (MAPE khoảng 10-15% tùy theo thiết bị) cung cấp cơ sở tin cậy cho việc quyết định triển khai.

**Nội dung 2:** Phát triển hệ thống điều phối MLOps theo kiến trúc Server – Agent

- Phương pháp: Phát triển thành phần Server quản lý kho mô hình, lưu trữ các phiên bản đã tối ưu và tích hợp điều phối dựa trên kết quả dự báo để quyết định mô hình phù hợp với thiết bị biên. Agent được thực thi tại biên sử dụng các giao thức API và backend (Node.js/Python) để giao tiếp và điều phối. Chịu trách nhiệm thực thi mô hình, thu thập dữ liệu Telemetry (nhiệt độ, pin, độ trễ) gửi về Server.
- Kết quả dự kiến: Hệ thống nguyên mẫu hỗ trợ OTA ổn định, cơ chế canary/rollback hoạt động chính xác khi gặp lỗi hoặc vượt ngưỡng tài nguyên đảm bảo tính sẵn sàng cao.

**Nội dung 3:** Tích hợp ngữ cảnh trạm giám sát y tế thông minh vào hệ thống triển khai

- Phương pháp: Sử dụng các tập dữ liệu phát hiện té ngã có sẵn để thực hiện tiền xử lý và trích xuất đặc trưng hình ảnh/video. Thực hiện huấn luyện mô hình trên môi trường Server, sau đó áp dụng kỹ thuật lượng tử hóa (Quantization) và chuyển đổi sang định dạng ONNX/TFLite để giảm độ trễ và tiêu thụ năng lượng khi thực thi. Đóng gói mô hình thành các artifact để Edge Agent thực hiện suy luận thời gian thực, đồng thời tích hợp với Dashboard để hiển thị cảnh báo và dữ liệu telemetry.
- Kết quả dự kiến: Hệ thống triển khai thành công ứng dụng nhận diện té ngã với độ chính xác trên 85%, đảm bảo khả năng phản hồi thời gian thực nhờ kỹ thuật tối ưu hóa mô hình. Đồng thời, Dashboard sẽ hiển thị trực quan các dữ liệu Telemetry và cảnh báo sự kiện, đi kèm báo cáo đánh giá chi tiết về sự đánh đổi giữa độ chính xác và hiệu năng năng lượng.

**Giới hạn đề tài:**

- Đối tượng nghiên cứu: Tập trung vào quy trình đóng gói/phân phối mô hình (model artifact); cơ chế thu thập Telemetry; và thuật toán ra quyết định triển khai dựa trên ngưỡng vận hành. Ngữ cảnh trạm giám sát y tế thông minh (phát hiện té ngã qua camera) được sử dụng như một bài toán minh họa; mô hình fall detection được lựa chọn theo hướng sử dụng mô hình có sẵn/baseline và chuyển đổi, tối ưu ở mức triển khai để phù hợp với thiết bị biên.
- Phạm vi thực nghiệm: Đề tài tập trung thực hiện trên tối thiểu một thiết bị biên thuần CPU (ví dụ: Raspberry Pi/BeagleBone Black) và một thiết bị có hỗ trợ GPU (ví dụ: Jetson Nano hoặc tương đương).
- Trọng tâm: Khóa luận tập trung vào tính đúng đắn và khả năng vận hành của hệ

thống triển khai (tốc độ cập nhật, độ ổn định, khả năng giám sát và phục hồi). Đề tài ưu tiên việc tối ưu mức triển khai để phù hợp với thiết bị biên thay vì tập trung tối ưu độ chính xác học thuật của mô hình phát hiện té ngã đến mức SOTA (State-of-the-Art).

**5. Kế hoạch đánh giá và sản phẩm đầu ra dự kiến**

**Kế hoạch đánh giá**

Hệ thống được đánh giá trên thiết bị biên thật theo các nhóm tiêu chí:

- Chức năng triển khai: quản lý phiên bản mô hình, OTA update, kích hoạt mô hình, thu thập telemetry.
- Hiệu năng: latency (inference/end-to-end), thông lượng (FPS hoặc infer/s), CPU/GPU/RAM, nhiệt độ.
- Năng lượng: mWh/inference và mWh theo thời gian vận hành liên tục.
- Độ tin cậy cập nhật: tỉ lệ triển khai thành công, canary, thời gian phát hiện lỗi và rollback.
- Thử nghiệm tình huống: mất kết nối, quá nhiệt/quá tải, artifact lỗi để kiểm chứng khả năng phục hồi.

**Sản phẩm đầu ra (deliverables)**

- Hệ thống nguyên mẫu triển khai linh hoạt trên edge, gồm:
  - Server điều phối: model registry + policy triển khai + API + log triển khai.
  - Edge agent: OTA, runtime suy luận (ONNX Runtime/TFLite), telemetry, rollback.
  - Dashboard giám sát fleet theo thời gian thực.
- Bộ benchmark & dữ liệu đo năng lượng/telemetry để huấn luyện mô hình dự báo năng lượng.
- Case study té ngã: tích hợp mô hình có sẵn (UR Fall) để minh họa triển khai và vận hành.

**Kết quả mong đợi**

- Mô hình dự báo năng lượng đạt sai số phù hợp cho quyết định trước triển khai (mục tiêu MAPE ~10–15% tùy thiết bị).
- Chiến lược triển khai linh hoạt giúp giảm năng lượng và/hoặc giữ latency trong ngân sách so với triển khai tĩnh.
- OTA hoạt động ổn định; canary/rollback phục hồi nhanh khi vượt ngưỡng; kết quả thể hiện qua bảng/biểu đồ và log thực nghiệm.

**6. Kế hoạch thực hiện**

Thời gian thực hiện dự kiến trong 4 tháng (16 tuần). Nhóm gồm 02 sinh viên phối hợp theo hướng phân tách module hệ thống và tích hợp cuối kỳ nhằm đảm bảo tiến độ và khả năng kiểm thử trên thiết bị thật.

**Kế hoạch theo tuần (dự kiến):**

- Tuần 1-2: Khảo sát công trình liên quan; xác định yêu cầu, tiêu chí đánh giá và kịch bản thử nghiệm.
- Tuần 3-4: Thiết kế kiến trúc tổng thể; hoàn thiện chuẩn model artifact và quy trình OTA.
- Tuần 5-7: Xây dựng kịch bản benchmark; triển khai đo đạc và thu thập dữ liệu năng lượng/telemetry trên thiết bị CPU và Jetson Nano.

- Tuần 8-9: Phân tích dữ liệu; xây dựng và đánh giá mô hình dự báo năng lượng; tích hợp dự báo vào quy trình ra quyết định triển khai.
- Tuần 10-11: Tích hợp case study phát hiện té ngã bằng mô hình có sẵn; chuyển đổi/đóng gói ONNX hoặc TFLite; chạy thử trên thiết bị biên.
- Tuần 12-13: Hoàn thiện chiến lược triển khai linh hoạt (constraint-aware), canary và rollback dựa trên telemetry; hoàn thiện dashboard giám sát.
- Tuần 14: Thực nghiệm tổng hợp; so sánh triển khai tĩnh và linh hoạt theo năng lượng, độ trễ và độ ổn định.
- Tuần 15-16: Viết báo cáo khóa luận; hoàn thiện demo và chuẩn bị tài liệu bảo vệ.

**Phân công công việc (dự kiến):**

Sinh viên 1 tập trung vào thiết kế backend server, quản lý phiên bản/kho mô hình, xây dựng mô hình dự báo năng lượng và tích hợp cơ chế ra quyết định triển khai. Sinh viên 2 tập trung vào agent trên thiết bị biên, triển khai runtime suy luận, thu thập telemetry, dashboard giám sát và tích hợp case study phát hiện té ngã. Hai sinh viên phối hợp trong giai đoạn thực nghiệm tổng hợp, đánh giá và viết báo cáo.

**7. Tài liệu tham khảo** *(theo chuẩn IEEE):*

[1] M. Kępski and B. Kwolek, “Detecting Human Falls with 3-Axis Accelerometer and Depth Sensor,” in Proc. IEEE EMBC, 2014, pp. 770–773, doi: 10.1109/EMBC.2014.6943704.
[2] B. Kwolek and M. Kępski, “Improving fall detection by the use of depth sensor and accelerometer,” Neurocomputing, vol. 168, pp. 637–645, 2015, doi: 10.1016/j.neucom.2015.05.061.
[3] M. Kępski, “UR Fall Detection Dataset (URFD),” 2014. [Online]. Available: https://fenix.ur.edu.pl/mkepski/ds/uf.html (accessed: 2026-03-01).
[4] balena, “Deploy to your fleet,” balena Documentation. [Online]. Available: https://docs.balena.io/learn/deploy/deployment/ (accessed: 2026-03-01).
[5] ONNX Runtime, “ONNX Runtime Documentation.” [Online]. Available: https://onnxruntime.ai/docs/ (accessed: 2026-03-01).
[6] TensorFlow, “Post-training quantization (TensorFlow Lite),” 2022. [Online]. Available: https://www.tensorflow.org/model_optimization/guide/quantization/post_training (accessed: 2026-03-01).

| **Xác nhận của CBHD**<br>(Ký tên và ghi rõ họ tên) | **TP. HCM, ngày 01 tháng 03 năm 2026**<br>**Sinh viên**<br>(Ký tên và ghi rõ họ tên)<br><br>**Trần Thu Ngân**<br>**Hồ Thị Huỳnh My** |
|---|---|